



Chpt.2 Random Variables & Probability Distributions

第二章 随机变量及其分布



独立事件： A_1, A_2, \dots, A_n ，其任意多个事件的积事件的概率都等于各个事件概率的积，则 A_1, A_2, \dots, A_n 相互独立。

- 独立、互斥往往是根据实际意义去判断
- 利用独立的特性，把和事件的概率转化为对立事件--积事件的概率加以计算

全概率公式： 设 S 为随机试验 E 的样本空间， B_1, B_2, \dots, B_n 为 S 的一个划分，且 $P(B_i) > 0, i=1, 2, \dots, n$ 。则任意事件 A 的概率为

$$P(A) = P(A|B_1)P(B_1) + P(A|B_2)P(B_2) + \dots + P(A|B_n)P(B_n)$$



[Bayes定理]: B_1, B_2, \dots, B_n 为样本空间 S 的一个划分, 事件 A 的概率 $P(A) > 0, P(B_i) > 0 (i=1, 2, \dots, n)$, 则:

$$P(B_i | A) = \frac{P(A | B_i)P(B_i)}{\sum_{j=1}^n P(A | B_j)P(B_j)} \quad i = 1, 2, \dots, n$$

- Bayes定理是在观察到事件 A 已发生的条件下, 寻找导致 A 发生的每个原因的概率. 所以也称为**逆概率公式**。
- $P(B_i)$ 和 $P(B_i | A)$ 分别称为**先验概率**和**后验概率**。



基于Bayes理论的决策、判别

如何确定一个新开信用卡客户的信誉？

基本思路：根据过去存在的信用卡客户的基本信息与实际信誉建立一个模型，而后判断新开客户的信誉。属于模式分类问题，采取的是机器学习思想（Machine Learning）。

假设已有的大量信用卡客户记录（包含客户基本信息、客户类别标签）构成一个样本集 S ，共把客户分成了 M 类（如金牌、银牌、铜牌、一般、黑名单），记为 $S = \{c_1, \dots, c_i, \dots, c_M\}$ ，样本集 S 被划分为 c_1 、 c_2 、 \dots 、 c_M 。每类的概率（先验）为 $P(c_i)$ ， $i=1, 2, \dots, M$ 。

现在的问题是，对一个没有标示类别的样本 Y （新客户信息），判断其属于哪一类？

基于Bayes理论的决策、判别

当样本集非常大时，可以认为

$$P(c_i) = c_i \text{类样本数} / \text{总样本数}$$

对于一个待分类样本Y，根据Bayes定理，可得其属于 c_i 类的后验概率 $P(c_i/Y)$ ：

$$P(c_i/Y) = P(Y/c_i) \cdot P(c_i) / P(Y)$$

则可以看 $P(c_1/Y)$ 、 $P(c_2/Y)$ 、……、 $P(c_M/Y)$ 哪个大，就断定Y属于哪一类。或者说 $X \in c_K$

$$\begin{aligned} P(c_K / Y) &= \underset{i=1,2,\dots}{\text{Max}} P(c_i / Y) \\ &= \underset{i=1,2,\dots}{\text{Max}} P(Y / c_i) P(c_i) / P(Y) \end{aligned}$$

事实上只要计算 $\underset{i=1,2,\dots}{\text{Max}} P(Y / c_i) P(c_i)$ 就可。

式(2)是最大后验概率判决准则。

基于Bayes理论的决策、判别



注意到 $P(Y / c_i)P(c_i)$ 的计算中包含了 $P(Y / c_i)$

假设属性集合为 x_1 、 x_2 、...、 x_n ，那么在已经得到的数据集S中，我们可以统计得到

$$P(x_1 / c_i) \cdots P(x_n / c_i) \quad (i = 1, 2, \dots, n)$$

假设属性之间是独立的，则知道

$$P(X / c_i) = P(x_1 / c_i) \cdots P(x_n / c_i)$$

我们可以用原有集合中的 x_1 、 x_2 、.....、 x_n 伴随每个 c_i 出现的概率

$P(X / c_i)$ 来估计 $P(Y / c_i)$



概率研究中的Case Study方法是否能解决所有问题？

前已介绍一些概率模型、很多例子，都有代表性；

但是可以找出更多的例子进行研究，永无止境！

这种方法属于Case Study。

存在问题：不同的case之间有无本质、统一的东西？

进一步，不同的概率现象之间有什么样的联系？

2.1 Random Variables



2.1.1 Introduction

那么，概率函数是否可用？

概率函数定义在样本空间 S 上， $\forall A \in S$ 有 $P(A)$ 与之对应；但由于样本空间的多样性，导致样本描述的多样性，使抽取其共性变得困难。

对于数值函数我们已经有足够多的研究成果

自然希望把一般的概率问题 \longrightarrow 数值函数问题。

事件空间 \longleftrightarrow 实数集合

研究事件 \longrightarrow 研究数量

2.1 Random Variables




2.1.2 随机变量的定义

随机试验 E ，其样本空间为 $S=\{e\}$ ，如果对每个 $e \in S$ ，有一个实数 $X(e)$ 与之对应，就得到一个定义在 S 上的单值实函数 $X=X(e)$ ，它是一个因变量，且因 e 的随机性而具有随机性，称为**随机变量**。

$$S \xrightarrow{X(\cdot)} R_X$$

$$X: e \in S \rightarrow X(e) \in R_X$$



2.1 Random Variables



通过随机变量可以描述事件，随机变量本身取值有一定的概率，区别于其他普通函数。对于一个实数集合 L ，随机变量 X ， $\{X \in L\}$ 表示的是一个事件 A ：

$$\{X \in L\} \Leftrightarrow \{e \mid X(e) \in L\} = A$$

因此，

$$P\{X \in L\} = P\{e \mid X(e) \in L\}$$

Example 2.1 某射手每次射击命中率为0.02，现在不断地射击，直到命中目标为止。

可以定义” X =命中目标所需的射击次数”

$$R_x = \{1, 2, \dots\}$$

$$L_1 = \{100\}$$

$$\{X \in L_1\} \Leftrightarrow \{e \mid \text{射击到第100次命中}\}$$

$$L_2 = \{1, 2, \dots, 100\}$$

$$\{X \in L_2\} \Leftrightarrow \{e \mid \text{不多于100次命中目标}\}$$

有些试验结果本身就是数量描述的，构成了随机变量。

例如：高炮在一定的条件下射击，用 ρ 表示弹着点与目标之间的距离， ρ 就是随机变量；如以目标点为原点，建立直角坐标系，则弹着点 (x, y) 中的 x 、 y 均是随机变量， (x, y) 本身是一个二维随机变量。

2.1 Random Variables



Example 2.2 盒子中有 N 个白球、 M 个黑球，从中抽取 k 个 ($k \leq M+N$)，则以下量为随机变量

X = 取得的白球数

Y = 取得的黑球数

Z = 两种球个数的差

Example 2.3 某公共汽车站每5分钟有一辆汽车通过，如果某人到达该车站的时刻是随机的。那么，一般来说，他等车的时间 X 是一个随机变量。

注意：此处随机变量 X 的取值是一个连续区间 $[0, 5]$

2.2 Discrete Random Variables & Its Distribution



2.2.1 离散型随机变量的定义

若随机变量 X 可能取的值为有限个或可列无限个，则称 X 为离散型随机变量(discrete random variable)。

Example 2.4

[1] 上面例子中的射击命中次数 X ；

[2] 在 $[0, 1]$ 区间上方随机抛球，观察落到有理点 X 上的情形。

有理点为：

$0, 1$

$1/2$

$1/3, 2/3$

$1/4, 2/4, 3/4$

.....

2.2 Discrete Random Variables & Its Distribution



2.2.2 概率分布律

对离散型随机变量涉及到两点：[1] 随机变量所有可能的取值；[2] 取每个值得概率。

如果 X 所有可能的取值为 x_k ($k=1,2,\dots$)， X 取 x_k (即事件 $A=\{x=x_k\}$) 的概率记为

$$P\{x = x_k\} = p_k (k = 1, 2, \dots)$$

称之为离散随机变量 X 的概率分布或分布律。

其直观的表现是列表

$$\begin{pmatrix} x_1 & x_2 & \cdots & x_n & \cdots \\ p(x_1) & p(x_2) & \cdots & p(x_n) & \cdots \end{pmatrix}$$

2.2 Discrete Random Variables & Its Distribution




Example 2.5 如右图所示，从盒中任取3个球。取到的白球数 X 是一个随机变量。 X 可能取的值是0,1,2。取每个值的概率为：

$$P(X = 0) = \frac{C_3^3}{C_5^3} = \frac{1}{10}$$

$$P(X = 1) = \frac{C_3^2 C_2^1}{C_5^3} = \frac{6}{10}$$

$$P(X = 2) = \frac{C_3^1 C_2^2}{C_5^3} = \frac{3}{10}$$



其分布列为

X	0	1	2
p_i	0.1	0.6	0.3

Example 2.6 设随机变量 X 的分布列为

$$\begin{pmatrix} -2 & -1 & 0 & 1 & 2 \\ \frac{a-1}{4} & \frac{a+1}{4} & 0.1 & 0.2 & 0.1 \end{pmatrix}$$

求 $P\{-1 \leq X \leq 2\}$

解 (1) 由 $\frac{a-1}{4} + \frac{a+1}{4} + 0.1 + 0.2 + 0.1 = 1$

解得 $a = 1.2$

故分布列为 $\begin{pmatrix} -2 & -1 & 0 & 1 & 2 \\ 0.05 & 0.55 & 0.1 & 0.2 & 0.1 \end{pmatrix}$

$$\begin{aligned} (2) P\{-1 \leq X \leq 2\} &= \sum_{-1 \leq X \leq 2} p(x_i) \\ &= 0.55 + 0.1 + 0.2 + 0.1 \\ &= 0.95 \end{aligned}$$

2.2 Discrete Random Variables & Its Distribution



Example 巴斯卡分布 在伯努里试验中，每次成功的概率为 p 。
记直至得到第 r 次成功时的试验次数为 X ，求 X 的分布列。

解 $P\{X=k\}=P\{\text{前}k-1\text{次试验中有}r-1\text{次成功，有}k-r\text{次不成功，且第}k\text{次成功}\}$

$$= C_{k-1}^{r-1} p^{r-1} (1-p)^{k-r} p$$

$$= C_{k-1}^{r-1} p^r (1-p)^{k-r}$$

$$(k = r, r+1, r+2, \dots)$$



2.2.3 常见的概率分布

(一) 退化分布（单点分布）

设随机变量 X 只取一个常数值 c ，即

$$P(X=c)=1$$

称它为退化(degenerate)分布，又称为单点分布。

事实上， $\{X=c\}$ 是一概率为1的事件， X 可以看作一个常数，但有时我们宁愿把它看作（退化的）随机变量。

(二) 0-1分布（两点分布/Bernoulli分布）

随机变量 X 只取两个值0和1，满足分布：

$$P(X=0)=1-p \quad p>0$$

$$P(X=1)=p$$

称 X 服从参数为 p 的 0-1分布（也称伯努里分布）。



2.2.3 常见的概率分布

Example 2.7 2000件产品，有1990件合格品，10 件次品。
从中随机抽一件，规定 $e_1 = \{\text{取得的是合格品}\}$ ， $e_2 = \{\text{取得的是次品}\}$

定义随机变量 $X(e_1) = 0, X(e_2) = 1$
 $p = 10 / 2000 = 0.05$

X服从参数0.05的0-1分布，如定义。

- [1] 伯努里试验具有广泛性：电路‘断’与‘不断’，产品‘合格’与‘不合格’，种子‘发芽’与‘不发芽’，掷硬币得‘正面’与‘反面’，...
- [2] 任一伯努里试验（具有广泛性）的结果都可用伯努里分布描述



2.2.3 常见的概率分布

(三) 二项分布

对于n重伯努里 (Bernoulli) 试验, 假设每次成功的概率是p, 定义随机变量X描述n次试验中事件A可能发生的次数k

$$\begin{aligned} P\{X = k\} &= b(k, n, p) \\ &= C_n^k p^k (1-p)^{n-k} \quad (k = 0, 1, 2, \dots, n) \end{aligned}$$

称X服从参数为n和p的二项分布 (Binomial distribution), 记为 $X \sim b(n, p)$ 或 $X \sim B(n, p)$.



(三) 二项分布

二项分布是概率论中最重要的分布之一，应用很广

[在此，进一步体会把一般概率问题抽象为一个随机变量，用分布加以描述的意义]

(1) 考察某地 n 个人是否患某种非流行性疾病，患病人数 X 服从二项分布。

检查一人是否患某种非流行性疾病是一次伯努里试验，各人是否生这病可认为相互独立，并可近似认为患病的概率 p 相等。

(2) 保险公司对某种灾害 (自行车被盗，火灾，...) **保险**

各人发生此种灾害与否可认为相互独立，并假定概率相等。设一年间一人发生此种灾害的概率为 p ，则在参加此种保险的 n 人中发生此种灾害的人数 X 服从二项分布。



(三) 二项分布

(3) 碰运气能否通过英语四级考试

$$P\{X = k\} = b(k, 85, 0.25)$$

$$P\{X \geq 51\} = b(51, 85, 0.25) + b(52, 85, 0.25) + \cdots + b(85, 85, 0.25) \\ \approx 8.74 \times 10^{-12}$$

(4) 机房内 n 台同类计算机，在一年内每台损坏的概率为 p ，
则在一年时间内损坏的机器数 X 服从二项分布。

如此，我们要问这样的分布具有什么样的性质呢？

比如：我们看看一年内最多会坏多少台机器？

为保证工作，最多备多少台机器？

平均会坏多少？一般备多少台机器（平均）？



2.2.3 常见的概率分布

二项分布的重要性质

[1] $b(k, n, p) = b(n - k, n, 1 - p)$

这从二项分布的概率以及 $C_n^k = C_n^{n-k}$ 立即可得。

也可以这样理解： n 次试验中，事件 { k 次成功} 与事件 { $n-k$ 次不成功} 是同样的，而 { $n-k$ 次不成功} 的概率即为

$$b(n - k, n, 1 - p)$$

很多情况下二项分布的计算很复杂，有时备有相应的计算表格，但只限于 $p \leq 0.5$ 的情况，当 $p > 0.5$ 时就可利用上式来计算。

[2] 增减性以及最可能成功（发生）次数

对固定的 n 、 p ， 由于

$$\begin{aligned}\frac{b(k, n, p)}{b(k-1, n, p)} &= \frac{C_n^k p^k (1-p)^{n-k}}{C_n^{k-1} p^{k-1} (1-p)^{n-k+1}} \\ &= \frac{(n-k+1)p}{k(1-p)} \\ &= 1 + \frac{(n+1)p - k}{k(1-p)}\end{aligned}$$

上式是否大于1，主要看 $(n+1)p - k$ 的正负，或者说看 $(n+1)p$ 与 k 的大小问题。

当 $k < (n+1)p$ 时， $\frac{b(k, n, p)}{b(k-1, n, p)} > 1$ ， $b(k, n, p)$ 单调递增；

当 $k > (n+1)p$ 时， $\frac{b(k, n, p)}{b(k-1, n, p)} < 1$ ， $b(k, n, p)$ 单调递减；




[2] 增减性以及最可能成功（发生）次数

$(n+1)p$ 是整数且 $k=(n+1)p$ 时, $b(k, n, p) = b(k-1, n, p)$ 达最大值;

我们称 $m=(n+1)p$ 或 $(n+1)p-1$ 为最可能成功次数;

当 $(n+1)p$ 不是整数时, 最可能成功次数 $m = [(n+1)p]$

直观推断： 概率 p 是统计得到的, 现在做 n 次试验, 最可能的成功次数应该是 np 附近。





Example 2.8 邮局开设多少服务窗口合理

某居民区有 n 人，拟设一个邮局，开设 m 个服务窗口，每个窗口都办理所有业务。窗口数 m 太小，则经常派长队；窗口数 m 太大不经济。

假定在每一个指定时刻，小区 n 个人中每人是否去邮局是独立的，每人去邮局办理业务的概率都是 p 。

问题：“在营业中任意时刻保证每个窗口的排队人数（包括正在被服务的那个人）不超过 s ”这个事件的概率不小于 α （一般取 $\alpha = 0.80, 0.85, 0.90$ ），则至少需开设多少个窗口？

分析：假设在邮局办事的人数为 X ，有 k 个人在邮局的概率为

$$P\{X = k\} = C_n^k p^k (1-p)^{n-k} \quad k = 0, 1, 2, \dots, n$$



Example 2.8 邮局开设多少服务窗口合理

“在营业中任意时刻每个窗口的排队人数（包括正在被服务的那个人）不超过s”这件事相当于m个窗口总的人数X：{ $X \leq sm$ } 这个事件。其发生的概率为

$$P\{X \leq sm\} = \sum_{k=0}^{sm} P\{X = k\} = \sum_{k=0}^{sm} C_n^k p^k (1-p)^{n-k}$$

题目要求此概率大于 α ，即

$$\sum_{k=0}^{sm} C_n^k p^k (1-p)^{n-k} \geq \alpha$$

找一个自然数m，使得上述不等式成立，**此m即为问题的答案。**



[3] $n \rightarrow \infty$ 时的渐近性质

假定 p 与 n 有关, 记作 p_n 。考虑 $n \rightarrow \infty$ 的情况, 有下面的定理:

[泊松(Poisson)定理] 如果存在正常数 λ , 当 $n \rightarrow \infty$ 时有 $np_n \rightarrow \lambda$, 则

$$\lim_{n \rightarrow \infty} b(k, n, p) = \frac{\lambda^k}{k!} e^{-\lambda} \quad k=0,1,2,\dots$$



[3] $n \rightarrow \infty$ 时的渐近性质

Proof: 记 $\lambda_n = np_n$

$$\begin{aligned} b(k, n, p) &= C_n^k (p_n)^k (1 - p_n)^{n-k} \\ &= \frac{n(n-1)(n-2)\cdots(n-k+1)}{k!} \left(\frac{\lambda_n}{n}\right)^k \left(1 - \frac{\lambda_n}{n}\right)^{(n-k)} \\ &= \frac{\lambda_n^k}{k!} \frac{n(n-1)(n-2)\cdots(n-k+1)}{n^k} \left(1 - \frac{\lambda_n}{n}\right)^n \bigg/ \left(1 - \frac{\lambda_n}{n}\right)^k \\ &\quad \begin{array}{cccc} \downarrow & \downarrow & \downarrow & \downarrow \\ \boxed{\frac{\lambda^k}{k!}} & \boxed{1} & \boxed{e^{-\lambda}} & \boxed{1} \end{array} \\ &\rightarrow \frac{\lambda^k}{k!} e^{-\lambda} \quad (n \rightarrow \infty) \end{aligned}$$



[3] $n \rightarrow \infty$ 时的渐近性质

$$\lim_{n \rightarrow \infty} b(k, n, p) = \frac{\lambda^k}{k!} e^{-\lambda} \quad k=0,1,2,\dots$$

定理的条件 $np_n \rightarrow \lambda$ 意味着当 n 很大时, p_n 必定很小.

因此, 利用泊松定理, 对于二项分布, 当 n 很大, p 很小时有以下近似式:

$$C_n^k p^k (1-p)^{n-k} \approx \frac{\lambda^k e^{-\lambda}}{k!}$$

其中 $\lambda = np$

实际计算中, $n \geq 100$, $np \leq 10$ 时近似效果就很好.



Example 2.9 为保证设备正常工作，要配备适量的维修人员。

设共有300台设备，每台的工作相互独立，发生故障的概率都是0.01. 在通常情况下，一台设备的故障可由一人来处理。

问：至少应配备多少维修人员，才能保证当设备发生故障时不能及时维修的概率小于0.01?

分析：

设 X 为300台设备同时发生故障的台数，300台设备独立工作，每台出故障概率 $p=0.01$. 可看作 $n=300$ 的伯努里概型.

可见， $X \sim B(n, p)$, $n=300, p=0.01$

设需配备 N 个维修人员，所求问题就是满足 $P(X > N) < 0.01$ 或 $P(X \leq N) \geq 0.99$ 的最小的 N .

$$\begin{aligned}
 P\{X > N\} &= \sum_{k=N+1}^{300} C_{300}^k (0.01)^k (0.99)^{300-k} \\
 &\approx \sum_{k=N+1}^{300} \frac{3^k e^{-3}}{k!} \\
 &\approx \sum_{k=N+1}^{\infty} \frac{3^k e^{-3}}{k!}
 \end{aligned}$$

我们求满足 $\sum_{k=N+1}^{\infty} \frac{3^k e^{-3}}{k!} < 0.01$ 的最小的 N .

查泊松分布表得

$$\sum_{k=9}^{\infty} \frac{e^{-3} 3^k}{k!} \approx 0.0038, \quad \sum_{k=8}^{\infty} \frac{e^{-3} 3^k}{k!} \approx 0.012$$

$K = N+1 \geq 9$ 即可, 即 $N \geq 8$. 即至少需配备8个维修人员.



(四) 泊松分布(Poisson)

从上面的泊松定理可引入另一类重要的分布。

设随机变量 X 可取一切非负整数值，取这些值的概率为：

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda} \quad k = 0, 1, 2, \dots$$

其中 $\lambda > 0$ 是它的参数，称 X 服从参数为 λ 的泊松分布，简记 $X \sim \pi(\lambda)$

容易知道：

$$P\{X = k\} > 0 \quad (k = 0, 1, 2, \dots)$$

$$\sum_{k=0}^{\infty} P\{X = k\} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = 1$$

泊松分布的背景

考虑在白天一分钟内某电话交换台接到的呼叫数 X 的分布， X 可能取值范围为 $0,1,2,\dots$ 。那么， X 服从何种分布？

我们采用**分割-求和-取极限**的方法来剖析。

[1] 首先把一分钟分割成 n 个足够小的区间（对等划分），假设每个区间只可能呼叫一次，对应的呼叫概率均为 p_n ，可以视 n 个小区间的呼叫为 n 重Bernoulli试验

[2] 在其中有 k 次呼叫的概率为 $b(k, n, p) = C_n^k (p_n)^k (1 - p_n)^{n-k}$

假设在一分钟内的呼叫次数的统计平均数为 λ ，则 $np_n = \lambda$

[3] 取 n 足够的大， $n \gg \lambda$ ，由Bernoulli定理，我们知道

$$b(k, n, p) \rightarrow \frac{\lambda^k}{k!} e^{-\lambda} \quad (n \rightarrow \infty)$$



2.2.3 常见的概率分布

(四) 泊松分布(Poisson)

Remark 1 这说明电话交换台在一分钟内呼叫的次数 X 满足参数为 λ 的泊松分布 $X \sim \pi(\lambda)$ 。 λ 的含义恰恰是在一分钟内的呼叫次数的统计平均数

Remark 2 这也说明泊松分布是 n 重Bernoulli分布的极限。当 n 足够大时, p 较小, 可以近似有

$$b(k, n, p) \sim \frac{\lambda^k}{k!} e^{-\lambda}$$



2.2.3 常见的概率分布

(五) 几何分布

单次试验中事件 A 发生概率为 p ，现重复多次，直到 A 出现为止。定义 X 为事件 A 首次发生时所进行的试验次数，则 X 为一随机变量，可能的取值为

$$P(X = k) = (1 - p)^{k-1} p \quad (k = 1, 2, \dots)$$

称 X 服从参数为 p 的几何分布

几何分布的无记忆性

假定在前 m 次试验中，事件 A 一直没有发生，则从第 $m+1$ 次开始直到成功的次数 Y 也服从同样的几何分布(实验次数 Y 与 m 无关, 好像把前面 m 次失败 ‘忘记’ 了)。

(证明见《概率论引论》，汪仁宫，pp.57)

2.3 Distribution Function of Random Variable

2.3.1 WHY and HOW

WHY: 分布列不能表示很多的随机变量之分布, 比如机器的寿命, 无法一一罗列这些值及其概率, 有必要引入概率分布的新的表示法。

HOW: 定义区间 $(-\infty, x]$ 上的概率

- 事实上, 我们经常关心的是一个随机变量落入一个区间、空间的概率, 如机器寿命大于 T 的概率, 产品中次品数少于 k 件的概率。
- 注意到随机变量取值为实数, 可以说分布在实数轴上的任意的区间 $(x_1, x_2]$ 都可以用 $(-\infty, x]$ 来表示, 进一步的由于任意波雷尔集 B 是左开右闭区间的 (有限或可列) 并、(有限或可列) 交、逆产生的集合, 故此可以定义在区间 $(-\infty, x]$ 上概率。



2.3 Distribution Function of Random Variable

2.3.2 定义

设随机变量 X ，对任意的实数 x ，随机变量 X 取值落入区间 $(-\infty, x]$ 内的概率为 $F(x)$

$$F(x) = P(X \leq x) \quad -\infty < x < +\infty$$

称为随机变量 X 的分布函数 (distribution function)。

[1] 对确定的随机变量 X ，其分布函数 $F(x)$ 是唯一确定的，它是实变量 x 的函数，因此我们可以利用实变函数论这一有力工具来研究随机变量。

[2] 有了分布函数，则对任一波雷尔集 A ，概率 $P(A)$ 可以用分布函数来表示。

$$\begin{aligned} P(a < X \leq b) &= P\{(-\infty, b]\} - P\{(-\infty, a]\} \\ &= F(b) - F(a) \end{aligned}$$



2.3 Distribution Function of Random Variable

2.3.3 分布函数的特性

由于分布函数已经是一个普通函数，就可以用数学分析、实变函数来研究。至此已经达到目的：

概率事件 \Rightarrow 随机变量(统一描述) \Rightarrow 分布函数(函数工具)

(1) $F(x)$ 是一个不减的函数, $\forall x_1 \leq x_2, F(x_1) \leq F(x_2)$

(2) $0 \leq F(x) \leq 1$

(3) $F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0$ $F(\infty) = \lim_{x \rightarrow \infty} F(x) = 1$

(4) 函数的右连续性 $F(x+0) = \lim_{y \rightarrow x+0} F(y)$

(严格证明见：《概率论》，王仁宫，pp.38, pp.66)

2.3 Distribution Function of Random Variable




Example 2.7 离散随机变量的分布函数，随机变量 X 的分布列为

$$\begin{pmatrix} x_1 & x_2 & \cdots & x_k & \cdots \\ p(x_1) & p(x_2) & \cdots & p(x_k) & \cdots \end{pmatrix}$$

且 $x_1 < x_2 < \cdots < x_k < \cdots$ ，则 X 的分布函数为 $F(x) = P(X \leq x) = \sum_{x_k \leq x} p_k$

$$F(x) = \begin{cases} 0, & x < x_1, \\ p(x_1), & x_1 \leq x < x_2, \\ \cdots & \cdots \\ \sum_{i \leq k} p(x_i), & x_k \leq x < x_{k+1}, \\ \cdots & \cdots \end{cases}$$



2.3 Distribution Function of Random Variable



它是间断的分段函数，在 x_k ($k=1, 2, \dots$)各有一跳跃，跃度为 $p(x_k)$ ，在每一段 $[x_k, x_{k+1})$ 中都是常数，呈阶梯形。

比如，随机变量 X 的分布律为

X	-1	2	3
p	1/4	1/2	1/4

X 的分布函数为 $F(x)$

$$F(x) = \begin{cases} 0 & x < -1 \\ P(X = -1) & -1 \leq x < 2 \\ P\{X = -1\} + P\{X = 2\} & 2 \leq x < 3 \\ 1 & x \geq 3 \end{cases}$$

2.3 Distribution Function of Random Variable




$$F(x) = \begin{cases} 0 & x < -1 \\ \frac{1}{4} & -1 \leq x < 2 \\ \frac{3}{4} & 2 \leq x < 3 \\ 1 & x \geq 3 \end{cases}$$

$$P\left\{X \leq \frac{1}{2}\right\} = F\left(\frac{1}{2}\right) = \frac{1}{4}$$

$$P\left\{\frac{3}{2} < X \leq \frac{5}{2}\right\} = F\left(\frac{5}{2}\right) - F\left(\frac{1}{2}\right) = \frac{1}{2}$$

$$\begin{aligned} P\{2 \leq X \leq 3\} &= F(3) - F(2) + P(X = 2) \\ &= \frac{3}{4} \end{aligned}$$





Example (pp.50 例2)

一个半径为2米的圆盘形靶子，设击中靶上任何一同心圆上的点的概率与该圆的面积成正比，并设射击都能中靶，以 X 表示弹着点与圆心的距离。

求：随机变量 X 的分布函数

解：如图，


[1] 若 $x < 0$ ，则 $\{X \leq x\}$ 是不可能事件

$$F(x) = P\{X \leq x\} = 0$$

[2] 若 $0 \leq x \leq 2$ ，由假设知道 $\{0 \leq X \leq x\}$ 的概率正比于圆的面积 πx^2

$$P\{0 \leq X \leq x\} = k \pi x^2$$

其中 k 为常数



当 $x=2$ 时, 有 $P\{0 \leq X \leq x\} = k \pi 4 = 1$

求得 $k \pi = 1/4$

于是有 $P\{0 \leq X \leq x\} = x^2/4$

$$F(x) = P\{X \leq x\} = P(X < 0) + P\{0 \leq X \leq x\} = x^2/4$$

[3] 若 $x \geq 2$, 由题意 $\{X \leq x\}$ 是必然事件

$$F(x) = P\{X \leq x\} = 1$$


综合以上知道:

$$F(x) = \begin{cases} 0 & x < 0 \\ \frac{x^2}{4} & 0 \leq x < 2 \\ 1 & x \geq 2 \end{cases}$$

同时分布函数可以写为积分形式

$$F(x) = \int_{-\infty}^x f(t) dt$$

$$f(t) = \begin{cases} \frac{t}{2} & 0 < t < 2 \\ 0 & \text{其他} \end{cases}$$





Question

1. What is random variables?
2. Why define random variable?
3. What is Distribution Function?
4. What is the difference between Probability Function and Distribution Function?



Review

随机变量：样本空间为 $S=\{e\}$ ，如果对每个 $e\in S$ ，有一个实数 $X(e)$ 与之对应，就得到一个定义在 S 上的单值实函数 $X=X(e)$ 。
 X 就称为**随机变量**。

$$P\{X \in L\} = P\{D\}, \quad D = \{e \mid X(e) \in L\}$$

分布函数：设随机变量 X ，对任意实数 x ， X 取值落入区间内的概率为 $F(x)$

$$F(x) = P(X \leq x), \quad -\infty < x < +\infty$$

$F(x)$ 表示的是什么？它表示的是这样一个随机事件的概率值：

事件： $A = \{e \mid X(e) \leq x\}$

$$F(x) = P\{A\} \equiv P\{e \mid X(e) \leq x\}$$

如果是在一点 x 的概率是多少呢？



2.4 Distribution for Continuous Random Variables

2.4.1 连续型随机变量及密度函数

猜测连续型随机变量的分布函数（依据）：

- [1] 概率定义一再地引用几何面积的概念；
- [2] 对于一个随机变量 X 取得某个区间的所有值时，从离散随机变量的分布函数为概率的和。

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt$$

Definition 1 如果对于随机变量 X 的分布函数 $F(x)$ ，存在非负函数 $f(x)$ ，使对于任意实数 x 满足

$$F(x) = \int_{-\infty}^x f(t)dt$$

则称 X 为连续型(continuous)随机变量，称 $f(x)$ 为 X 的概率密度函数，简称为密度函数(density function)。



2.4 Distribution for Continuous Random Variables

2.4.2 连续型随机变量的特性

连续型随机变量的分布函数 $F(x)$ 具有下列数学性质：

(1) 由实变函数论可以证明， $F(x)$ 必定处处连续；在 $f(x)$ 的连续点， $F(x)$ 可导，且 $F'(x) = f(x)$.

$$(2) \int_{-\infty}^{+\infty} f(x)dx = 1.$$

(3) 随机变量 X 落在任意区间 $(a, b]$ 的概率：

$$\begin{aligned} P\{a < x \leq b\} &= F(b) - F(a) \\ &= \int_a^b f(x)dx. \end{aligned}$$

良好的性质

(4) 特别，对任一常数 c ， $P\{X = c\} = 0$.



2.4 Distribution for Continuous Random Variables

Remark 1: 对连续型随机变量，计算在一点的概率是没有意义的，这也是不能用分布列描写连续型随机变量的理由之一。

Remark 2: 对连续型随机变量 $\{X=C\}$ 是一个可能发生的事件，因此一事件 A 的概率为 0 并不表明 $A=\emptyset$ （如在一个区间上方抛点，点可以落到任意一点 x ，但是落到任意一点的概率为 0）；同样若 $P(A)=1$ ，也并不表明 $A=S$ （样本空间）。

Remark 3: 除了离散型，连续型以外，随机变量还有其它类型吗？

$$F(x) = \begin{cases} 0, & x < 0, \\ (1+x)/2, & 0 \leq x < 1, \\ 1, & x > 1. \end{cases}$$

是分布函数，它不是离散型的，也不是连续型的（因为 $F(x)$ 本身就不连续）。



2.4.3 常见的连续型随机变量

[一] 均匀(Uniform)分布

考虑在一个区间 $[a, b]$ 上方抛点，假设点落入任意一个等长度区间的概率（可能性）是相同的（或者说点落入某个区间的可能性大小只与区间长度有关，与区间端点无关），用随机变量 X 表示区间的端点 $(-\infty, x]$ ，则 X 的分布函数为

$$F(x) = P\{X \leq x\} = \begin{cases} 0, & x \leq a \\ \frac{x-a}{b-a}, & a < x < b \\ 1, & x \geq b \end{cases}$$
$$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b, \\ 0, & \text{else} \end{cases}$$

称具有上述概率密度的连续型随机变量 X 为在区间 $[a, b]$ 上服从均匀分布，简记作 $X \sim U(a, b)$ 。



2.4.3 常见的连续型随机变量

[一] 均匀 (Uniform) 分布

Example 考察一个数据，它在小数点 n 位后四舍五入，则其真值 x 与其近似值 \hat{x} 之间的误差 $\varepsilon = \hat{x} - x$ ，一般假定服从 $[-0.5 \times 10^{-n}, 0.5 \times 10^{-n}]$ 上的均匀分布。

利用均匀分布理论可以对大量运算后的数据进行误差分析。这对于使用计算机解题时是很重要的，因为计算机的字长总是有限的。

Example 列车从车站每40分钟开出一辆，乘客到站时刻是机会均等的，问等候超过10分钟的概率是多少？

以 T 表示等候时间，它是一个随机变量。 $P\{t_1 < T \leq t_1 + \Delta t\}$ 指在区间 $[t, t + \Delta t]$ 等到车的概率。

T 取值范围为 $[0, 40]$ ，其服从均匀分布 $U[0, 40]$ 。

$$P\{T \geq 10\} = 1 - P\{T \leq 10\} = \int_{10}^{40} \frac{1}{40} dt = \frac{3}{4}$$



2.4.3 常见的连续型随机变量

[二] 指数 (Exponential) 分布

随机变量 X 的密度函数为（当然，我们说它应该满足分布密度）

$$f(x) = \begin{cases} \frac{1}{\theta} e^{-x/\theta} = \frac{1}{\theta} \text{Exp}\left(-\frac{x}{\theta}\right), & x > 0 \\ 0, & \text{else} \end{cases}$$

其中 $\theta > 0$ 为常数，则称 X 服从参数为 θ 的指数分布 (Exponential)。

其分布函数为

$$F(x) = \begin{cases} 1 - e^{-x/\theta}, & x > 0 \\ 0, & \text{else} \end{cases}$$

指数分布常用来描述产品的寿命。



[二] 指数分布

Example 若是用了 t 小时的电子管，在以后的 Δt 小时内失效的概率为 $\lambda \Delta t + o(\Delta t)$ ，其中 λ 是不依赖于 t 的正常数，求电子管在 T 小时内失效的概率（假定电子管寿命为 0 的概率是 0）。

解： 设 X 为电子管的寿命。注意，对于成批的电子管而言， X 是一个随机变量。按题意要找出 $P\{X \leq T\}$ ，即要找出 X 的分布函数 $F(t)$ ，求 $F(t)$ 在 T 点的值。

从问题给出的条件入手，其可以表示为：

$$P\{t < X < t + \Delta t \mid t < X\} = \lambda \Delta t + o(\Delta t)$$

$$\frac{P\{(t < X < t + \Delta t) \cap (t < X)\}}{P\{t < X\}} = \lambda \Delta t + o(\Delta t)$$

$$\frac{P\{(t < X < t + \Delta t)\}}{P\{t < X\}} = \lambda \Delta t + o(\Delta t)$$



[二] 指数分布

$$\frac{F(t + \Delta t) - F(t)}{1 - F(t)} = \lambda \Delta t + o(\Delta t)$$

$$\frac{F(t + \Delta t) - F(t)}{\Delta t} = \lambda(1 - F(t)) + o(\Delta t) / \Delta t$$

$$F'(t) = \lambda(1 - F(t))$$

解此线性微分方程组（注意到初始条件 $F(0)=0$ ），解得

$$F(t) = 1 - e^{-\lambda t}$$

X 有密度函数

$$f(t) = \begin{cases} \lambda e^{-\lambda t} & t > 0 \\ 0 & \text{else} \end{cases}$$

电子管在 T 小时内失效的概率为 $1 - e^{-\lambda T}$.

注意：寿命 \longleftrightarrow 失效的对立性

寿命为 T 小时的概率为 $1 - F(T) = e^{-\lambda T}$.



[二] 指数分布

指数分布具有类似几何分布的“无记忆性”：使用 s 小时后元件的寿命不低于 t 的概率与初始时使用寿命为 t 的概率相等。

事实上，设随机变量 ξ 服从参数为 λ 的指数分布，则对于任意的 $s > 0$, $t > 0$,

$$P\{(\xi > s+t) \cap (\xi > s)\}$$

$$P(\xi > s+t | \xi > s) = P(\xi > s+t, \xi > s) / P(\xi > s)$$

$$= e^{-\lambda(s+t)} / e^{-\lambda s}$$

$$= e^{-\lambda t}$$

$$= P(\xi > t)$$



[三] 正态分布

若随机变量 X 的密度函数为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad -\infty < x < \infty$$

就称 X 服从正态(Normal)分布，记作 $X \sim N(\mu, \sigma^2)$ 。其中， $\sigma > 0$ ， $-\infty < \mu < \infty$ 。

我们来证明上述定义的 $f(x)$ 的确是密度函数。

显然 $f(x) > 0$;

进一步证明 $\int_{-\infty}^{\infty} f(x) dx = 1$ ，即证明

$$\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = 1 \xrightarrow{t=\frac{x-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt = 1.$$



[三] 正态分布

$$\int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx = 1 \xrightarrow{t=\frac{x-\mu}{\sigma}} \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt = 1.$$

$$\begin{aligned} \left[\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt \right]^2 &= \frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} e^{-\frac{s^2}{2}} dt ds \\ &= \frac{1}{2\pi} \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{-\frac{t^2+s^2}{2}} dt ds \end{aligned}$$

上述二重积分可用极坐标表示成

$$\frac{1}{2\pi} \int_0^{2\pi} d\theta \int_0^{\infty} e^{-\frac{1}{2}r^2} r dr = \int_0^{\infty} e^{-\frac{1}{2}r^2} r dr = 1.$$

也即 $\int_{-\infty}^{\infty} f(x) = 1.$



2.4 Distribution for Continuous Random Variables

Remark 1: 正态分布是概率论中最重要的一种分布，与二项分布、泊松分布并称为三大分布。

正态分布是19世纪初高斯（Gauss）在研究测量误差时首次引进的，故正态分布又称误差分布或高斯分布。

Remark 2: 对正态分布应用很广，一般说来，若影响某一数量指标的随机因素很多，而每一因素所起的作用又不很大，则这个数量指标服从正态分布。例如进行测量时，由于仪器精度、人的视力、心理因素、外界干扰等多种因素影响，测量结果大致服从正态分布，测量误差也服从正态分布。

Remark 3: 正态分布具有良好的性质，一定条件下，很多分布可用正态分布来近似表达；另一些分布又可以通过正态分布来导出，因此，正态分布在理论研究中也相当重要。



1. 正态分布的特性

正态分布的密度曲线是一条关于纵轴对称的钟形曲线。特点是“两头小，中间大，左右对称”。

[1] 曲线 $f(x)$ 关于 $x=\mu$ 对称。

$$f(\mu - x) = f(\mu + x) \quad P\{\mu - h < X < \mu\} = P\{\mu < X < \mu + h\}$$

[2] 当 $x=\mu$ 时， $f(x)$ 取得最大值 $\frac{1}{\sqrt{2\pi}\sigma}$

当 $x < \mu$ 时， $f(x)$ 单调递增；

当 $x > \mu$ 时， $f(x)$ 单调递减；

$x \rightarrow \infty$ 时， $f(x) \rightarrow 0$ 。


这些表明， x 离 μ 越远， $f(x)$ 的值越小。对于同样长度的区间，当区间离 μ 越远时， X 落在此区间的概率越小。



1. 正态分布的特性

[3] σ^2 （方差）越大，最高点越低， $f(x)$ 的图形越扁平，说明 X 分布比较分散， X 取值离开 μ 点远的概率也越大；

σ^2 （方差）越小，最高点越高，说明 X 分布比较集中； $f(x)$ 的图形越陡峭， X 取值越集中在点 μ 附近。






1. 正态分布的特性

[4] 固定 σ ，改变 μ 的值，则图形沿着 x 轴平移，而不改变其形状。。

可见正态分布的概率密度曲线的位置完全由参数 μ 决定， μ 称为位置参数。



[1] μ 、 σ 分别称为均值与均方差；

[2] 考研：四科成绩分布，希望是均值尽量高（总分过线），方差也要尽量小（别偏科）。

甲：总分307，英语60，政治65，数学85，专业97

乙：总分312，英语46，政治65，数学101，专业100

丙：总分264，英语51，政治51，数学81，专业81



1. 正态分布的特性

[5] 当 $\mu=0, \sigma=1$ 时, 称为标准正态分布(standardized normal distribution), 它的密度曲线关于纵轴对称, 其密度及分布函数特别记为 $\varphi(x)$ 和 $\Phi(x)$:

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad -\infty < x < \infty$$

容易知道 $\Phi(-x) = 1 - \Phi(x)$.



2. 正态分布的计算

[1] 标准正态分布概率的计算

标准正态分布的计算不容易，有专门的表格供查阅。

当 $x \geq 0$ 时，每隔一定数值，可以查到对应的分布函数 $\Phi(x)$ 的值；在这些数值之间，用线性插值法求得相应的函数值；（附录中这个间隔是纵向排列的，间隔是0.1，插补为0.01，横向排列）。

当 $x < 0$ 时，注意到

$$\Phi(-x) = 1 - \Phi(x).$$

结合 $-x > 0$ 时的 $\Phi(-x)$ 表就可算出 $x < 0$ 时 $\Phi(x)$ 的值。



2. 正态分布的计算

Example 设 $X \sim N(0, 1)$ 。

- (1) 计算 $P\{-1 < X < 3\}$;
- (2) 已知 $P\{X < \lambda\} = 0.9755$, 求 λ 。

解: (1)
$$\begin{aligned} P(-1 < X < 3) &= P(X < 3) - P(X < -1) \\ &= \Phi(3) - \Phi(-1) \\ &= \Phi(3) - (1 - \Phi(1)) \\ &= 0.9987 + 0.8413 - 1 \\ &= 0.8400 \end{aligned}$$



2. 正态分布的计算

(2) $\Phi(\lambda)=0.9755$, 求 λ 。

我们倒查表格, 看看0.9755对应的值是多少。

但是, 表格没有这样的值, 只有相近的。

$$\Phi(1.96) = 0.9750 < \Phi(\lambda) < \Phi(1.97) = 0.9756$$

由于 $\Phi(x)$ 是单调不减的, 故 λ 在1.96与1.97之间

$$1.96 < \lambda < 1.97$$

在这个小的范围内, 我们把 λ 与 $\Phi(\lambda)$ 的关系近似看作线性:

$$\begin{aligned}\frac{\lambda - 1.96}{1.97 - 1.96} &\approx \frac{\Phi(\lambda) - \Phi(1.96)}{\Phi(1.97) - \Phi(1.96)} \\ \lambda &\approx 1.96 + \frac{\Phi(\lambda) - \Phi(1.96)}{\Phi(1.97) - \Phi(1.96)} (1.97 - 1.96) \\ &\approx 1.968\end{aligned}$$

以上思路称为**线性插值法**。



3. 一般正态分布的概率计算

对一般的 $X \sim N(\mu, \sigma^2)$ ，可以变换为标准正态分布加以计算。
记 $Y = (X - \mu) / \sigma$ (称为 X 的标准化随机变量)，则 Y 服从 $N(0, 1)$ 。
事实上 Y 的分布函数 $F_y(y)$

$$\begin{aligned} F_y(y) &= P\{Y \leq y\} \\ &= P\{X \leq \sigma y + \mu\} \\ &= \int_{-\infty}^{\sigma y + \mu} \frac{1}{\sqrt{2\pi}\sigma} \text{Exp}\left(-\frac{(t - \mu)^2}{2\sigma^2}\right) dt \\ &\quad \downarrow z = \frac{t - \mu}{\sigma} \\ &= \int_{-\infty}^y \frac{1}{\sqrt{2\pi}} \text{Exp}\left(-\frac{z^2}{2}\right) dz \end{aligned}$$



3. 一般正态分布的概率计算

由此可知： $X \sim N(\mu, \sigma^2)$ ，则

$$\begin{aligned} P\{X \leq x\} &= P\left\{\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right\} \\ &= P\left\{Y \leq \frac{x - \mu}{\sigma}\right\} \\ &= \Phi\left\{\frac{x - \mu}{\sigma}\right\} \end{aligned}$$

对于任意的区间 $(x_1, x_2]$

$$\begin{aligned} P\{x_1 < X \leq x_2\} &= P\left\{\frac{x_1 - \mu}{\sigma} < \frac{X - \mu}{\sigma} \leq \frac{x_2 - \mu}{\sigma}\right\} \\ &= \Phi\left(\frac{x_2 - \mu}{\sigma}\right) - \Phi\left(\frac{x_1 - \mu}{\sigma}\right) \end{aligned}$$



3. 一般正态分布的概率计算

Example 汽车设计手册中指出：人的身高服从正态分布 $X \sim N(\mu, \sigma^2)$ 。根据各国统计资料，可得各国、各民族男子身高的 μ 和 σ 。对于中国人， $\mu = 1.75$ ， $\sigma = 0.05$ 。现要求上下车时要低头的人不超过0.5%，车门需要多高？

解： 设大巴士车车门高位 h ， X 为乘客的身高，则 $X \sim N(1.75, 0.05^2)$ ，根据题意

$$P\{X \leq h\} \geq 99.5\%$$

$$P\left\{\frac{X - 1.75}{0.05} \leq \frac{h - 1.75}{0.05}\right\} \geq 99.5\%$$

$$\Phi\left(\frac{h - 1.75}{0.05}\right) \geq 99.5\%$$

$$\frac{h - 1.75}{0.05} \geq 2.58$$

$$h \geq 1.879$$

如此，知道车门应该高1.88米。



3. 一般正态分布的概率计算

Example 从南郊某地乘车到北区火车站有两条路可走，第一条路较短，但交通拥挤，所需时间 T_1 服从 $N(50, 100)$ 分布；第二条路线略长，但意外阻塞较少，所需时间 T_2 服从 $N(60, 16)$ 。

(1) 若有70分钟可用，问应走哪一条路？

(2) 若只有65分钟可用，又应走哪一条路？

分析： 应该走在允许时间内有较大概率赶到火车站的路线。

解： (1) 若有70分钟可用

走第一条路线及时赶到的概率。

$$\begin{aligned} P\{T_1 \leq 70\} &= \Phi\left(\frac{70-50}{10}\right) \\ &= \Phi(2) \\ &= 0.9772 \end{aligned}$$

走第二条路线及时赶到的概率。

$$\begin{aligned} P\{T_2 \leq 70\} &= \Phi\left(\frac{70-60}{4}\right) \\ &= \Phi(2.5) \\ &= 0.9938 \end{aligned}$$

在这种场合，应走第二条路线。



3. 一般正态分布的概率计算

(2) 若只有65分钟可用，又应走哪一条路？

走第一条路线及时赶到火车站的概率为

$$P\{T_1 \leq 65\} = \Phi\left(\frac{65-50}{10}\right) = \Phi(1.5) = 0.9332$$

走第二条路线及时赶到的概率为

$$P\{T_2 \leq 65\} = \Phi\left(\frac{65-60}{4}\right) = \Phi(1.25) = 0.8944$$

因此在这种场合，应走第一条路线更为保险。

Remark: 此处的 μ 和 σ 的含义分别是走完这段路程所需要的平均时间和均方差。



3. 一般正态分布的概率计算

Example 设 $X \sim N(\mu, \sigma^2)$,

求 $P\{|X - \mu| < \sigma\}, P\{|X - \mu| < 2\sigma\}, P\{|X - \mu| < 3\sigma\}$

解: $Y = (X - \mu) / \sigma$, 则 $Y \sim N(0, 1)$, 故由标准正态分布函数 $\Phi(y)$,

$$\begin{aligned} \text{可以求得 } P\{|X - \mu| < k\sigma\} &= P\left\{-k < \frac{X - \mu}{\sigma} < k\right\} \\ &= \Phi(k) - \Phi(-k) \\ &= 2\Phi(k) - 1 \end{aligned}$$

$$P\{|X - \mu| < \sigma\} = 2\Phi(1) - 1 \approx 0.6826$$

$$P\{|X - \mu| < 2\sigma\} = 2\Phi(2) - 1 \approx 0.9544$$

$$P\{|X - \mu| < 3\sigma\} = 2\Phi(3) - 1 \approx 0.9973$$

说明正态随机变量的99.73 %的值落在 $(\mu - 3\sigma, \mu + 3\sigma)$ 之中, 落在该区间之外的概率几乎为零, 这情况被实际工作者称为“**3 σ 原则**”。



2.5 随机变量的函数及其分布-I

人们经常碰到随机变量的函数。例如分子运动动能 $T = mv^2/2$ 是分子运动速度—随机变量 v 的函数；

数理统计中经常用到 $\chi^2(n)$ 分布，相应的随机变量

$$\chi^2 = \xi_1^2 + \xi_2^2 + \cdots + \xi_n^2$$

其中各 ξ_i 相互独立，都服从 $N(0, 1)$ 。 χ^2 是 ξ_1, \dots, ξ_n 的函数。

一般地，若 X 是随机变量， $y = g(x)$ 是普通的实函数，则 $Y = g(X)$ 是 X 的函数。

产生两个问题：

- (1) Y 是随机变量吗？
- (2) 如果是， Y 的分布与 X 的分布有什么关系？



2.5.1 离散型随机变量的函数

Example (pp.62 例1) 假设随机变量 X 具有如下分布律

求： $Y = (X - 1)^2$ 的分布。

解： Y 的可能取值为0,1,4, 是有限个,
只须算出对应的概率。由于

X	-1	0	1	2
p_n	0.2	0.3	0.1	0.4

$$P\{Y=0\} = P\{X=1\} = 0.1,$$

$$\text{故 } P\{Y=1\} = P\{X=0\} + P\{X=2\} = 0.7$$

$$P\{Y=4\} = P\{X = -1\} = 0.2$$

类似可得其它概率。我们得到 Y 的分布：

Y	0	1	4
p_n	0.1	0.7	0.2

一般, 设 X 有分布列 $P\{X = x_i\} = p\{x_i\}$, $i=1,2,\dots$, 则

$$Y=f(X) \text{ 有分布列 } P\{Y = y_j\} = \sum_{f(x_i)=y_j} p(x_i), \quad j=1,2,\dots$$



2.5.1 离散型随机变量的函数

例2 设 $X \sim B(n_1, p)$, $Y \sim B(n_2, p)$, X 、 Y 相互独立,

求: $Z = X + Y$ 的分布。

解: X, Y 各可取值 $0, 1, \dots, n_1$ 和 $0, 1, \dots, n_2$, 则 Z 可取值 $0, 1, \dots, n_1 + n_2$, 得

$$\begin{aligned} P\{Z = s\} &= \sum_{k=0}^s P\{X = k, Y = s - k\} \\ &= \sum_{k=0}^s P\{X = k\} P\{Y = s - k\} \\ &= \sum_{k=0}^s C_{n_1}^k p^k (1-p)^{n_1-k} C_{n_2}^{s-k} p^{s-k} (1-p)^{n_2-(s-k)} \\ &= p^s (1-p)^{n_1+n_2-s} \sum_{k=0}^s C_{n_1}^k C_{n_2}^{s-k} \\ &= C_{n_1+n_2}^s p^s (1-p)^{n_1+n_2-s} \end{aligned}$$

$$X+Y \sim B(n_1+n_2, p)$$



2.5.1 离散型随机变量的函数

Remark1: 上面公式的推导用到了组合数的性质。

$$\sum_{k=0}^s C_{n_1}^k C_{n_2}^{s-k} = C_{n_1+n_2}^s$$

Remark2: $X+Y \sim B(n_1+n_2, p)$ 这个事实显示了二项分布一个很重要的性质：两个独立的二项分布，当它们的第二参数相同时，其和也服从二项分布，它的第一参数恰为这两个二项分布第一参数的和。

- 这性质称为二项分布的再生性(或可加性(additive property))
- 从 X, Y 的概率意义来看，这结果是非常明显的： X 和 Y 分别是 n_1 和 n_2 重贝努里试验中成功的次数，两组试验合起来， $Z=X+Y$ 应该就是 n_1+n_2 重贝努里试验中成功的次数。



2.5.2 一维连续型随机变量的函数的分布

设 X 的密度函数为 $f_X(x)$ ，我们要求出 $Y = g(X)$ 的分布函数 $F_Y(y)$ 。
事实上

$$\begin{aligned} F_Y(y) &= P(Y \leq y) = P(g(X) \leq y) \\ &= P(X \in D) \end{aligned}$$

而 $D = \{x \mid g(x) \leq y\}$ 是一维的波雷尔集，故

$$F_Y(y) = P(X \in D) = \int_{x \in D} f_X(x) dx$$

至于 Y 是不是连续型随机变量，它的密度函数是什么，在一般场合无法作出决定，但在某些特殊而又常见的场合，我们可以直接导出 Y 的密度函数 $f_Y(y)$ 。



2.5.2 一维连续型随机变量的函数的分布

Example $X \sim N(0, 1)$, 求 $Y = X^2$ 的密度。

解：先求分布函数 $F_Y(y)$ ，再微分求得 $f_Y(y)$ 。

$$\begin{aligned} F_Y(y) &= P(Y \leq y) \\ &= P(X^2 \leq y) \\ &= \begin{cases} 0 & y \leq 0 \\ P(-\sqrt{y} < X < \sqrt{y}) & y > 0 \end{cases} \\ &= \begin{cases} 0 & y \leq 0 \\ \int_{-\sqrt{y}}^{\sqrt{y}} f_X(x) dx & y > 0 \end{cases} \\ f_Y(y) &= \begin{cases} 0 & y \leq 0 \\ \frac{1}{2\sqrt{y}} [f_X(\sqrt{y}) + f_X(-\sqrt{y})] & y > 0 \end{cases} \end{aligned}$$



2.5.2 一维连续型随机变量的函数的分布

当 $X \sim N(0,1)$ 时, $Y = X^2$

$$f_Y(y) = \begin{cases} \frac{1}{2\sqrt{y}} \left(\frac{1}{\sqrt{2\pi}} e^{-y/2} + \frac{1}{\sqrt{2\pi}} e^{-y/2} \right) & y > 0 \\ 0 & y \leq 0 \end{cases}$$
$$= \begin{cases} \frac{1}{\sqrt{2\pi}} y^{-1/2} e^{-y/2} & y > 0 \\ 0 & y \leq 0 \end{cases}$$

此时称 Y 服从自由度为1的 $\chi^2(1)$ 分布, 它也是 Γ -分布的一种。



2.5.2 一维连续型随机变量的函数的分布

某些情形下，我们可以直接导出 Y 的密度函数 $f_Y(y)$ 。

定理1 X 为连续型随机变量，有概率密度函数

$$f_X(x) (-\infty < x < \infty)$$

若 $g(X)$ 严格单调且处处可导，则 $Y = g(X)$ 也是连续型随机变量。若令其中 $h(y)$ 是 $g(x)$ 的反函数，则 Y 的密度函数为

$$f_Y(y) = \begin{cases} |h'(y)| f_X[h(y)] & y \in g(x) \text{ 的值域} \\ 0 & y \in \text{其它} \end{cases}$$



2.5.2 一维连续型随机变量的函数的分布

证：不妨设 $g(x)$ 严格单调增加，且 $-\infty < x < +\infty$ 时， $\alpha < g(x) < \beta$ 。显然若 $y \leq \alpha$ ，则 $F_Y(y) = 0$ ；若 $y > \beta$ ，则 $F_Y(y) = 1$ ，两种情形下都有 $f_Y(y) = 0$ 。当 $\alpha < y < \beta$ 时， $\{Y \leq y\} = \{g(X) \leq y\} = \{X \leq h(y)\}$ ，故

$$F_Y(y) = P(Y \leq y) = P(X \leq h(y)) = \int_{-\infty}^{h(y)} f_X(x) dx$$

$F_Y(y)$ 对 y 求导，得到 Y 的概率密度函数

$$f_Y(y) = \begin{cases} h'(y) f_X[h(y)] & y \in g(x) \text{ 的值域} \\ 0 & y \in \text{其他} \end{cases}$$

当 $y = f(x)$ 为严格单调减少时，类似可证：

$$f_Y(y) = \begin{cases} -h'(y) f_X[h(y)] & y \in g(x) \text{ 的值域} \\ 0 & y \in \text{其他} \end{cases}$$

二者结合，可得定理的结论。



2.5.2 一维连续型随机变量的函数的分布

Example 设 $X \sim N(\mu, \sigma^2)$, 求 $Y = aX + b$ 的密度函数 ($a \neq 0$)。

解: $y = g(x) = ax + b$ 满足上述定理1中的条件, $h(y) = (y - b)/a$

Y 的密度

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/2\sigma^2} \quad -\infty < x < \infty$$

$$f_Y(y) = f_X(h(y)) |h'(y)| \quad \text{结论: } Y \sim N(a\mu + b, (|a|\sigma)^2)$$

$$= \frac{1}{\sqrt{2\pi}\sigma} \text{Exp} \left(- \left(\frac{y-b}{a} - \mu \right)^2 / 2\sigma^2 \right) \times \frac{1}{|a|}$$

$$= \frac{1}{\sqrt{2\pi} |a| \sigma} \text{Exp} \left(- [y - (a\mu + b)]^2 / 2(a\sigma)^2 \right)$$

$$= \frac{1}{\sqrt{2\pi} |a| \sigma} e^{-[y - (a\mu + b)]^2 / 2(a\sigma)^2}$$